Fast Path e Full Path: Routing Suave

Nem toda query precisa do pipeline completo de retrieval. Rodar reranker cross-encoder e múltiplos canais de busca para uma pergunta trivial desperdiça latência e custo sem ganho de qualidade perceptível.

O problema do custo uniforme

Sem routing, toda query paga o mesmo preço: dense search, BM25, fusão RRF e reranker, mesmo quando a resposta está obviamente em um único chunk muito específico. Isso é especialmente caro quando o reranker está ativo, já que um cross-encoder pode ser dezenas de vezes mais lento que a busca inicial.

Dois caminhos, não dois sistemas

O fast path usa dense mais BM25 com fusao RRF uniforme, sem reranker. O full path adiciona o reranker cross-encoder sobre os candidatos do fast path. Nenhum canal de busca é eliminado em nenhum dos dois caminhos · apenas o reranker é opcional.

Estimando complexidade sem LLM

A classificação de complexidade usa heurística leve, sem chamada de LLM: numero de entidades na query, presença de termos comparativos como 'diferença entre' ou 'comparado a', e comprimento total da pergunta. Chamar um LLM só para decidir qual caminho seguir anularia o ganho de latência que o fast path deveria trazer.

Threshold de decisão

O valor de referência adotado nesta plataforma é threshold = 0.6 na escala de complexidade estimada: abaixo disso, fast path; a partir disso, full path. Esse valor é ajustado empiricamente comparando latência média e Recall@5 do golden dataset nos dois caminhos.