Reindexação Incremental: Grafo de Dependências

Reprocessar o corpus inteiro toda vez que um documento muda é inviável em escala. Um documento editado deve disparar apenas o recálculo dos chunks, embeddings e índices derivados dele · não do corpus inteiro.

Detectando mudança com hash

Cada Document ganha um content_hash calculado com SHA-256 sobre o conteúdo bruto do arquivo no momento do parsing. Antes de reprocessar, o sistema compara o hash novo com o hash salvo da última indexação: se forem iguais, nada precisa ser refeito.

O grafo de dependências

A relação document_id para chunk_ids para embedding_ids é modelada como um grafo de dependências simples. Quando um documento muda, o sistema navega o grafo a partir do document_id afetado e invalida somente os nós downstream · os chunks daquele documento e os embeddings correspondentes no Qdrant e no Postgres.

Fluxo de invalidação

Ao detectar hash diferente: 1) remove os chunks antigos daquele document_id nos índices dense e BM25; 2) roda o parser e o chunker novamente sobre o conteúdo atualizado; 3) reindexa apenas os chunks novos. Documentos não tocados nunca entram nesse fluxo.