Analise Comparativa de Estrategias RAG

Este documento apresenta metricas de avaliacao offline de diferentes configuracoes do pipeline RAG, incluindo estrategias de chunking, modelos de embedding e configuracoes de retrieval.

1. Metricas de Performance por Estrategia de Retrieval

A tabela abaixo apresenta os resultados de avaliacao offline (golden dataset, 33 perguntas) para diferentes combinacoes de estrategia de retrieval. Latencia medida com modelo BGE-M3 em CPU.

Estrategia	Recall@5	MRR	Latencia (ms)	Custo/Query (USD)
Dense (BGE-M3)	0.8788	0.7121	520	0.00000
BM25 (Postgres)	0.7576	0.6364	18	0.00000
Hibrido RRF (sem reranker)	0.9394	0.7576	540	0.00000
Hibrido RRF (fast path)	0.9697	0.7864	560	0.00000
Hibrido RRF (full path + reranker)	0.9697	0.8182	1320	0.00000

Nota: O full path com reranker tem MRR 4% superior ao fast path, mas latencia 2.4x maior. O fast path e o padrao para queries simples.

2. Comparativo de Modelos de Embedding

Comparacao de modelos de embedding candidatos para uso no pipeline RAG. Recall@5 medido no corpus seed de 12 documentos, 33 perguntas. Velocidade medida em CPU (Intel i7, single thread).

Modelo	Dimensao	Recall@5	Velocidade (ms/doc)	Parametros	Custo (USD/1M tokens)
BAAI/bge-m3	1024	0.9697	1565	568M	0.00 (local)
text-embedding-3-small	1536	0.9394	45	n/a	0.020
text-embedding-3-large	3072	0.9697	62	n/a	0.130
BAAI/bge-small-en-v1.5	384	0.8485	210	33M	0.00 (local)
sentence-transformers/all-MiniLM-L6-v2	384	0.7879	180	22M	0.00 (local)

O modelo BGE-M3 mantem Recall@5 de 0.9697 com custo zero (local), equivalente ao text-embedding-3-large da OpenAI a $0.13/1M tokens. Para migracao de modelo, manter collection paralela por 30 dias.

3. Evolucao do Recall@5 ao Longo dos Passos do Projeto

Esta tabela mostra como o Recall@5 evoluiu a cada passo de melhoria implementado no pipeline RAG, permitindo rastrear o impacto de cada mudanca na qualidade de retrieval.

Passo	Descricao	Recall@5	MRR	Delta Recall
Passo 6	Retrieval Hibrido RRF (baseline)	0.9394	0.7576	--
Passo 7	Golden dataset (33 perguntas)	0.9394	0.7576	+0.00
Passo 9	Reranker BGE adicionado	0.9697	0.8182	+0.03
Passo 13	Fast/Full path routing	0.9697	0.7864	0.00
Passo 14	Observabilidade (sem mudanca de pipeline)	0.9697	0.7864	0.00